

ETL Lab Report

Student ID : 67160244

Name : น.ส.เอมิกา อยู่พันธ์

1. Data Quality Problems Found

1.customer_id ซ้ำ : 2 รายการ

2.Province สะกดไม่ตรงกัน:

- ก่อน clean มีค่าที่ต่างกัน 16 แบบ : ['จันทบุรี', 'BKK', 'chon buri', 'ชลบุรี', 'Chanthaburi', 'กรุงเทพฯ', 'rayong', 'Rayong', 'RAYONG', 'CHANTHABURI', 'Bangkok', 'chantaburi', 'bangkok', 'CHONBURI', 'Chonburi', 'ระยอง']
- หลัง clean เหลือมาตรฐาน 5 แบบ : ['Chanthaburi', 'Bangkok', 'Chonburi', 'Rayong', 'Unknown']

3.Missing values ใน customers :

- email ว่าง : 1 รายการ
- province ว่าง : 1 รายการ

4.Products :

- product_id ซ้ำ : 0 รายการ
- คอลัมน์ดิบจาก JSON (มี nested field) : ['product_id', 'product_name', 'category.name', 'pricing.price']
- คอลัมน์หลัง flatten+rename: ['product_id', 'product_name', 'category', 'price']
- category ที่หายไปและถูกเติมเป็น 'Unknown' : 1 รายการ

5.Orders:

- order_id ซ้ำ : 3 รายการ

6.Order date หลายรูปแบบปนกัน ตัวอย่าง :

- 2026/08/02
- 01/08/2026
- 2026-08-01
- 03-Aug-2026
- 2026-08-04
- not-a-date

7.Order records ที่ผิดปกติ (นับจาก rejects.csv) :

- status_not_paid_or_completed: 76 รายการ
- invalid_qty: 1 รายการ
- invalid_unit_price: 1 รายการ
- invalid_discount_pct: 1 รายการ
- invalid_order_date: 1 รายการ

2. Cleaning / Transformation Rules

1.customer_id / product_id / order_id ซ้ำ -> ใช้
drop_duplicates(keep='first') เก็บแถวแรกเจอ

2.province สะกดไม่ตรงกัน -> map ผ่าน PROVINCE_MAP ให้เป็นค่ามาตรฐานเดียว (ตัวพิมพ์เล็ก+ภาษาไทย/อังกฤษ)

3.email/province/name ว่าง -> เติมค่า default ('Unknown',
'unknown@example.com') กัน NaN หลุดเข้า warehouse

4.products.json nested field (category.name, pricing.price) -> flatten ด้วย
pd.json_normalize() แล้ว rename เป็น category, price

5.category สินค้าว่าง -> เติมเป็น 'Unknown'

6.price เป็น string ปนสัญลักษณ์ -> แปลงเป็นตัวเลขด้วย
pd.to_numeric(errors='coerce')

7.order_date หลายรูปแบบ -> ลอง parse ตามลิสต์ format ที่ละแบบ (ISO ก่อน แล้วค่อย
DD/MM, MM/DD)

8.status ตัวพิมพ์ไม่ตรงกัน -> แปลงเป็น lowercase ทั้งหมดด้วย .str.lower()

9.qty<=0 / unit_price<=0 / discount_pct<0 หรือ>100 / date ผิด -> reject ออก
ไปที่ rejects.csv พร้อมระบุเหตุผล

10.status ไม่ใช่ paid/completed -> reject ไม่นับเป็นยอดขาย

11.customer_id/product_id ที่ไม่มีใน master -> reject แทนการปล่อยให้ join แล้วได้ค่า
ว่าง

3. Rejected Records

จำนวน : 80

เหตุผลหลัก :

- status_not_paid_or_completed: 76 รายการ
- invalid_qty: 1 รายการ
- invalid_unit_price: 1 รายการ
- invalid_discount_pct: 1 รายการ
- invalid_order_date: 1 รายการ

4. ETL Validation

- Valid transformed rows : 100
- Warehouse rows : 100
- Duplicate order_id : 0
- Source total sales : 192074.66
- Warehouse total sales : 192074.66
- Validation status : PASS

5. Idempotency Test

จำนวน fact_sales หลัง run ครั้งที่ 1 : 100

จำนวน fact_sales หลัง run ครั้งที่ 2 : 100

อธิบายผล : จำนวนเท่าเดิมเพราะ load.py ใช้ order_id เป็น PRIMARY KEY รวมกับคำสั่ง
INSERT ... ON CONFLICT DO UPDATE (upsert) ทำให้ถ้า order_id ซ้ำ ระบบจะอัปเดตแถว
เดิม แทนการเพิ่มแถวใหม่ จึงไม่มีข้อมูลซ้ำเมื่อรันซ้ำ